

Econometría

Diplomado Banco Central de Honduras

Instituto de Economía

Pontificia Universidad Católica de Chile

Juan Ignacio Urquiza – Junio 2022

¿Qué es la econometría?

- Es una disciplina que emplea la teoría económica y los métodos estadísticos para estudiar relaciones económicas, contrastar distintas teorías, pronosticar variables, y evaluar políticas en forma cuantitativa, utilizando bases de datos.
- Combina elementos de la teoría económica, las matemáticas y la estadística.
- Es una aplicación del método científico en economía.

Función de Esperanza Condicional


- Se define a la función de esperanza condicional (FEC) para una variable Y_i como su valor esperado cuando X_i está fijo:

$$FEC: E(Y_i | X_i)$$

- Dado que X_i es una variable aleatoria, entonces la FEC es también aleatoria.
- También se puede definir la FEC para un valor particular de X_i . Por ejemplo:

$$E(Y_i | X_i = x)$$

Ejemplo



Ley de Esperanzas Iteradas

- La LEI es un complemento importante, que permite obtener el valor esperado de Y_i a partir del promedio de todas las FEC.

$$E(Y_i) = E[E(Y_i|X_i)]$$

- Por lo tanto, nos permite descomponer a cualquier variable aleatoria tal que:

$$Y_i = E(Y_i|X_i) + \varepsilon_i$$

donde $E(\varepsilon_i|X_i) = 0$ y ε_i es ortogonal a cualquier función de X_i .


Descomposición de la FEC

- Esto implica que siempre podemos representar a una variable aleatoria Y_i como la suma de su esperanza condicional a X_i más algo que no está relacionado a X_i .
- Además, se puede demostrar que la FEC es el mejor predictor de Y_i dado X_i – menor error cuadrático medio.
- Por lo tanto, la FEC es una buena manera de caracterizar la relación entre X_i e Y_i .

Función de Regresión Poblacional

- ¿Cuál es la relación entre la FEC y la función de regresión poblacional (FRP)?
- Podemos pensar en la FRP como un acercamiento a la FEC.
- En particular, se puede demostrar que:
 - ▣ Si la FEC es lineal, entonces la FEC es la FRP.
 - ▣ La FRP es el mejor predictor *lineal* de Y_i dado X_i .
 - ▣ La FRP es la mejor aproximación lineal de la FEC.

Ejemplo



Modelo de Regresión Lineal Simple

□ MRL Simple:

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

- Y : variable dependiente, explicada, predicha, de respuesta, regresando...
- X : variable independiente, explicativa, predictora, de control, regresor...
- β_0, β_1 : parámetros poblacionales desconocidos.
- ε : término de error o perturbación inobservable.
 - Representa factores distintos de X que afectan a Y .

Ejemplos

□ Ecuación de salarios:

- Y: salario
- X: años de educación
- ε : experiencia laboral, capacidad/habilidad innata, años de antigüedad en la empresa...

□ Rendimiento y fertilizante:

- Y: rendimiento de un cultivo
- X: cantidad de fertilizante
- ε : calidad de la tierra, lluvia, sol...

Modelo de Regresión Lineal Múltiple

□ MRL Múltiple:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_K X_K + \varepsilon$$

donde β_0 es la constante o el intercepto y $\beta_{i \neq 0}$ es el parámetro de pendiente asociado a una de las K variables explicativas.

- ▣ Note que hay $K+1$ parámetros poblacionales desconocidos.
- Es importante destacar que el análisis de regresión no se aplica para determinar causalidad sino para ver si dos variables guardan una relación positiva o negativa.

Interpretación

- Los parámetros de la FRP muestran la relación entre X_j e Y , manteniendo todo lo demás constante.
- Es decir, los parámetros de pendiente representan el cambio esperado en Y ante un cambio en X_j , manteniendo todo lo demás constante:

$$\Delta E(Y|X_1, X_2, \dots, X_K) = \beta_j \Delta X_j$$

- Por lo tanto,

$$\beta_j = \frac{\Delta E(Y|X_1, X_2, \dots, X_K)}{\Delta X_j}$$

Estimación

- Sea el modelo de regresión lineal (MRL) simple:

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

- Nuestro objetivo consiste en estimar los parámetros poblacionales a partir de una muestra aleatoria.
- Para cada observación de la muestra $\{i = 1, 2, \dots, n\}$ se cumple que:

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$$

donde ε_i es el término de error para la observación i .

Estimación


- Al análogo muestral del término de error se lo conoce como “*residual o residuo*”.
- Definición: llamaremos residuo a la diferencia entre el “*valor observado*” y el “*valor ajustado*”:

$$\hat{\varepsilon}_i = Y_i - \hat{Y}_i = Y_i - (\hat{\beta}_0 + \hat{\beta}_1 X_i)$$

- Los estimadores de **Mínimos Cuadrados Ordinarios (MCO)** son los argumentos que minimizan la suma de los residuos al cuadrado:

$$\sum_{i=1}^n \hat{\varepsilon}_i^2 = \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i)^2$$

Valor observado vs. ajustado



Estimación

- Este criterio penaliza más a los residuos más grandes.
- CPO:

$$\sum_i \hat{\varepsilon}_i = 0 \quad \Rightarrow \quad \hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$

$$\sum_i X_i \hat{\varepsilon}_i = 0 \quad \Rightarrow \quad \hat{\beta}_1 = \frac{\sum_i (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_i (X_i - \bar{X})^2}$$

- Implicancia:
 - ▣ Si en la muestra X e Y se correlacionan positivamente (negativamente), entonces $\hat{\beta}_1$ es positivo (negativo).

Forma matricial

- Sea el modelo de regresión lineal (MRL) múltiple:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_K X_K + \varepsilon$$

- En términos matriciales, se puede representar de la siguiente manera:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

- ▣ En este caso, las letras minúsculas representan **vectores** y las mayúsculas **matrices**.

Forma matricial

$$\begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} = \beta_0 \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{bmatrix} + \beta_1 \begin{bmatrix} x_{1,1} \\ x_{2,1} \\ \vdots \\ x_{n,1} \end{bmatrix} + \beta_2 \begin{bmatrix} x_{1,2} \\ x_{2,2} \\ \vdots \\ x_{n,2} \end{bmatrix} + \cdots + \beta_k \begin{bmatrix} x_{1,k} \\ x_{2,k} \\ \vdots \\ x_{n,k} \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

$$\begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & x_{1,1} & x_{1,2} & \cdots & x_{1,k} \\ 1 & x_{2,1} & x_{2,2} & \cdots & x_{2,k} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n,1} & x_{n,2} & \cdots & x_{n,k} \end{bmatrix} \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

Estimación

- Se debe minimizar la suma de cuadrados residuales.
- ¿Cómo?

$$\begin{aligned}\rightarrow SCR &= \hat{\varepsilon}'\hat{\varepsilon} = (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}})'(\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}) \\ &= \mathbf{y}'\mathbf{y} - \hat{\boldsymbol{\beta}}'\mathbf{X}'\mathbf{y} - \mathbf{y}'\mathbf{X}\hat{\boldsymbol{\beta}} + \hat{\boldsymbol{\beta}}'\mathbf{X}'\mathbf{X}\hat{\boldsymbol{\beta}} \\ &= \mathbf{y}'\mathbf{y} - 2\mathbf{y}'\mathbf{X}\hat{\boldsymbol{\beta}} + \hat{\boldsymbol{\beta}}'\mathbf{X}'\mathbf{X}\hat{\boldsymbol{\beta}}\end{aligned}$$

puesto que, tratándose de escalares, $(\hat{\boldsymbol{\beta}}'\mathbf{X}'\mathbf{y}) = (\mathbf{y}'\mathbf{X}\hat{\boldsymbol{\beta}})$.

- Reglas para la diferenciación:

$$\frac{\partial \mathbf{X}\hat{\boldsymbol{\beta}}}{\partial \hat{\boldsymbol{\beta}}} = \mathbf{X}$$

$$\frac{\partial \hat{\boldsymbol{\beta}}'\mathbf{C}\hat{\boldsymbol{\beta}}}{\partial \hat{\boldsymbol{\beta}}} = 2\mathbf{C}\hat{\boldsymbol{\beta}}$$

Estimación

- Sea el MRL múltiple en notación matricial:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

- Se debe minimizar la suma de cuadrados de residuales.

$$\begin{aligned}\min_{\hat{\boldsymbol{\beta}}} SCR &= \min_{\hat{\boldsymbol{\beta}}} (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}})' (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}) \\ &= \mathbf{y}'\mathbf{y} - 2\mathbf{y}'\mathbf{X}\hat{\boldsymbol{\beta}} + \hat{\boldsymbol{\beta}}'\mathbf{X}'\mathbf{X}\hat{\boldsymbol{\beta}}\end{aligned}$$

- CPO:

$$\frac{\partial SCR}{\partial \hat{\boldsymbol{\beta}}} = \mathbf{0} \quad \rightarrow \quad -2\mathbf{X}'\mathbf{y} + 2(\mathbf{X}'\mathbf{X})\hat{\boldsymbol{\beta}} = \mathbf{0}$$

Estimación

- Por lo tanto, tenemos que:

$$\hat{\beta} = (X'X)^{-1}X'y$$

- El vector $\hat{\beta}$ recibe el nombre de estimador de MCO.
- Para que esta solución sea efectivamente un mínimo es necesario que:

$$\frac{\partial SCR}{\partial \hat{\beta} \partial \hat{\beta}'} = 2(X'X)$$

sea definida positiva.

- Puesto que X es de rango completo (RLM.3), entonces $\hat{\beta}$ es único y minimiza la suma de cuadrados residuales.

Ejemplo

- Usted dispone de los siguientes datos muestrales:

x	y
0	4
1	6
2	7
3	9
4	11

- $n = 5, k = 1$.
- Estime la regresión simple de Y sobre X por MCO.

Ejemplo

- Caracterización de X e y :

$$X = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \end{bmatrix}, \quad y = \begin{bmatrix} 4 \\ 6 \\ 7 \\ 9 \\ 11 \end{bmatrix}$$

- Estimador de MCO:

$$\hat{\beta} = (X'X)^{-1}(X'y)$$

Ejemplo

- Cálculo de la matriz $(X'X)^{-1}$:

$$X'X = \begin{bmatrix} 1 & 1 & 1 & 1 & 1 \\ 0 & 1 & 2 & 3 & 4 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \end{bmatrix}$$

$$X'X = \begin{bmatrix} 5 & 10 \\ 10 & 30 \end{bmatrix}$$

$$(X'X)^{-1} = \begin{bmatrix} 0.6 & -0.2 \\ -0.2 & 0.1 \end{bmatrix}$$

Ejemplo

- Cómputo del vector $X'y$:

$$X'y = \begin{bmatrix} 1 & 1 & 1 & 1 & 1 \\ 0 & 1 & 2 & 3 & 4 \end{bmatrix} \begin{bmatrix} 4 \\ 6 \\ 7 \\ 9 \\ 11 \end{bmatrix}$$

$$X'y = \begin{bmatrix} 37 \\ 91 \end{bmatrix}$$

- Cálculo de los estimadores:

$$\hat{\beta} = \begin{bmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \end{bmatrix} = \begin{bmatrix} 0.6 & -0.2 \\ -0.2 & 0.1 \end{bmatrix} \begin{bmatrix} 37 \\ 91 \end{bmatrix} = \begin{bmatrix} 4 \\ 1.7 \end{bmatrix}$$

Propiedades algebraicas

- Las propiedades algebraicas se derivan de las llamadas ecuaciones normales para MCO.

- Recuerde que:

$$-X'y + (X'X)\hat{\beta} = 0$$

$$-X'(y - X\hat{\beta}) = 0$$

$$-X'\hat{u} = 0 \rightarrow X'\hat{u} = 0$$

- Esto implica que los residuos suman cero y que son ortogonales a los regresores.

- Además, implica que: $\hat{\beta}'X'\hat{u} = \hat{y}'\hat{u} = 0$.

Ejemplo

□ Curva de regresión muestral: $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$

x	y	\hat{y}	$\hat{u} = y - \hat{y}$	$x * \hat{u}$	$\hat{y} * \hat{u}$
0	4	4	0	0	0
1	6	5,7	0,3	0,3	1,71
2	7	7,4	-0,4	-0,8	-2,96
3	9	9,1	-0,1	-0,3	-0,91
4	11	10,8	0,2	0,8	2,16
		SUMA=	0	0	0

Descomposición de la varianza

- Sea SCT la suma de cuadrados totales:

$$SCT = \sum_{i=1}^n (y_i - \bar{y})^2$$

- Sea SCE la suma de cuadrados explicados:

$$SCE = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$$

- Sea SCR la suma de cuadrados residuales:

$$SCR = \sum_{i=1}^n \hat{u}_i^2$$

Bondad del ajuste

- Entonces, se puede demostrar que:

$$SCT = SCE + SCR$$

- A partir de esta descomposición, se define el R^2 o coeficiente de determinación como:

$$R^2 = \frac{SCE}{SCT} = 1 - \frac{SCR}{SCT}$$

- Dado que $0 \leq SCE \leq SCT$, entonces $0 \leq R^2 \leq 1$.
- Corresponde a la proporción de la variación muestral de y que es explicada por la regresión de MCO.

Bondad del ajuste

- Resulta interesante destacar que el R^2 nunca disminuye cuando se agregan variables explicativas al modelo.
- Esto ocurre incluso si las variables que se agregan no son relevantes en el modelo poblacional.
- Se necesita de una medida que ajuste por la cantidad de regresores. Se define entonces al R^2 ajustado como:

$$\bar{R}^2 = 1 - \frac{(n - 1)}{(n - k - 1)} \times \frac{SCR}{SCT}$$

- El principal atractivo es que penaliza por el número de regresores. Nótese que incluso podría ser negativo.

. reg testscr str

Source	SS	df	MS
Model	7794.11004	1	7794.11004
Residual	144315.484	418	345.252353
Total	152109.594	419	363.030056

Number of obs = 420
 F(1, 418) = 22.58
 Prob > F = 0.0000
 R-squared = 0.0512
 Adj R-squared = 0.0490
 Root MSE = 18.581

testscr	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
str	-2.279808	.4798256	-4.75	0.000	-3.22298	-1.336637
_cons	698.933	9.467491	73.82	0.000	680.3231	717.5428

. reg testscr str el_pct expn_stu

Source	SS	df	MS
Model	66409.8837	3	22136.6279
Residual	85699.7099	416	206.008918
Total	152109.594	419	363.030056

Number of obs = 420
 F(3, 416) = 107.45
 Prob > F = 0.0000
 R-squared = 0.4366
 Adj R-squared = 0.4325
 Root MSE = 14.353

testscr	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
str	-.2863992	.4805232	-0.60	0.551	-1.230955	.658157
el_pct	-.6560227	.0391059	-16.78	0.000	-.7328924	-.5791529
expn_stu	.0038679	.0014121	2.74	0.006	.0010921	.0066437
_cons	649.5779	15.20572	42.72	0.000	619.6883	679.4676