

Econometría

Diplomado Banco Central de Honduras

Instituto de Economía

Pontificia Universidad Católica de Chile

Juan Ignacio Urquiza – Junio 2022

Propiedades estadísticas

□ Supuestos:

- ▣ Linealidad en parámetros (RLM.1).
- ▣ Muestreo aleatorio (RLM.2).
- ▣ Colinealidad imperfecta (RLM.3).
- ▣ Media condicional cero (RLM.4).
- ▣ Homocedasticidad (RLM.5).

□ Se puede demostrar que:

- ▣ Bajo los supuestos RLM.1 a RLM.4, los estimadores de MCO son insesgados.
- ▣ Bajo los supuestos RLM.1 a RLM.5, son los de mínima varianza entre los estimadores lineales insesgados.

Supuestos

- Linealidad en parámetros (RLM.1):
 - ▣ La relación poblacional entre las variables sigue un modelo lineal:

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_k x_k + u = \mathbf{X}\beta + u$$

- ▣ Si el modelo analítico no es lineal, hay que linealizarlo.
 - ▣ Por ejemplo:

$$y = AK^{\beta_1}L^{\beta_2}$$

- ▣ Entonces:

$$\rightarrow \ln y = \beta_0 + \beta_1 \ln K + \beta_2 \ln L$$

Supuestos

- Muestreo aleatorio (RLM.2):

- ▣ Las observaciones provienen de una muestra aleatoria de la población:

$$\{(x_{i1}, x_{i2}, \dots, x_{ik}, y_i) : i = 1, 2, \dots, n\}$$

- ▣ Esto significa que las observaciones son independientes:

$$\text{cov}(u_i, u_j | \mathbf{X}) = 0 \quad \forall i \neq j$$

- ▣ En un contexto de series de tiempo, esto implica que los errores no tienen autocorrelación.

Supuestos

- Colinealidad imperfecta (RLM.3):
 - ▣ No hay relaciones lineales exactas entre las variables independientes.
 - ▣ Los regresores pueden estar correlacionados entre sí, sólo que no pueden hacerlo en forma perfecta.
 - ▣ Esto permite la identificación de los parámetros.
 - ▣ Sin embargo, tal como lo veremos más adelante, una colinealidad alta dificulta la identificación.

Supuestos

- Media condicional cero – $E(\mathbf{u}|\mathbf{X}) = \mathbf{0}$ (RLM.4):
 - ▣ También se puede escribir como $E(u|x_1, \dots, x_k) = 0$.
 - ▣ Significa que ninguno de los factores en el término del error correlaciona con las variables explicativas.
 - ▣ Implica que:

$$E(\mathbf{y}|\mathbf{X}) = E(\mathbf{X}\boldsymbol{\beta} + \mathbf{u}|\mathbf{X}) = \mathbf{X}\boldsymbol{\beta}$$


$$E[E(\mathbf{u}|\mathbf{X})] = E(\mathbf{u}) = \mathbf{0}$$

- ▣ Este supuesto puede no cumplirse por varias razones:
 - Especificación incorrecta de la forma funcional, omisión de variables relevantes, errores de medición, etc.


Supuestos

- Homocedasticidad – $V(\mathbf{u}|\mathbf{X}) = \sigma^2 \mathbf{I}$ (RLM.5):
 - ▣ También se puede escribir como $V(u|x_1, \dots, x_k) = \sigma^2$.
 - ▣ Es decir, la varianza del error no depende de haber observado una realización particular de X .
 - ▣ Cuando este supuesto no se cumple, se dice que el modelo presenta heterocedasticidad.
 - ▣ ¿Gráficamente?

Test score



Test score



Propiedades estadísticas

□ Insesgamiento:

$$\begin{aligned}\hat{\beta} &= (X'X)^{-1}X'y \\ &= (X'X)^{-1}X'(X\beta + u) \\ &= \beta + (X'X)^{-1}X'u\end{aligned}$$

▣ Por lo tanto:

$$\begin{aligned}E(\hat{\beta}|X) &= \beta + (X'X)^{-1}X'E(u|X) = \beta \\ \rightarrow E(\hat{\beta}) &= E[E(\hat{\beta}|X)] = \beta\end{aligned}$$

- ▣ Esto implica que el promedio de los estimadores $\hat{\beta}$ obtenidos a partir de todas las muestras aleatorias posibles es igual a β .

Propiedades estadísticas

□ Varianza:

$$V(\hat{\beta}|X) = \sigma^2(X'X)^{-1}$$

$$\begin{aligned} V(\hat{\beta}|X) &= E[(\hat{\beta} - \beta)(\hat{\beta} - \beta)' | X] \\ &= E[(X'X)^{-1}X'u u'X(X'X)^{-1} | X] \\ &= (X'X)^{-1}X'E[uu' | X]X(X'X)^{-1} \\ &= (X'X)^{-1}X'(\sigma^2 I)X(X'X)^{-1} \\ &= \sigma^2(X'X)^{-1}X'X(X'X)^{-1} \\ &= \sigma^2(X'X)^{-1} \end{aligned}$$

Teorema de Gauss-Markov

- Cualquier estimador lineal de β se puede escribir como:

$$\tilde{\beta} = A'y = A'(X\beta + u) = A'X\beta + A'u$$

- Para que $\tilde{\beta}$ sea insesgado:

$$E(\tilde{\beta}|X) = A'X\beta + A'E(u|X) = A'X\beta = \beta \leftrightarrow A'X = I$$

- ¿Varianza?

$$V(\tilde{\beta}|X) = A'V(u|X)A = \sigma^2 A'A$$

- Por lo tanto:

$$\begin{aligned} V(\tilde{\beta}|X) - V(\hat{\beta}|X) &= \sigma^2 [A'A - (X'X)^{-1}] \\ &= \sigma^2 [A'A - A'X(X'X)^{-1}X'A] \end{aligned}$$

Teorema de Gauss-Markov

- Por lo tanto:

$$\begin{aligned} V(\tilde{\beta}|X) - V(\hat{\beta}|X) &= \sigma^2 A' [I - X(X'X)^{-1}X'] A \\ &= \sigma^2 A' M A \end{aligned}$$

- Dado que M es simétrica e idempotente, entonces $A' M A$ es semi-definida positiva.
- Esto implica que para cualquier vector c :

$$V(c'\tilde{\beta}|X) - V(c'\hat{\beta}|X) = c' [V(\tilde{\beta}|X) - V(\hat{\beta}|X)] c \geq 0$$

- Por lo tanto, esto establece que el estimador de MCO es el mejor estimador lineal insesgado (MELI).

Varianza del estimador de MCO

- Bajo los supuestos RLM.1 a RLM.5, se cumple que:

$$V(\hat{\beta}_j | \mathbf{X}) = \frac{\sigma^2}{SCT_j \times (1 - R_j^2)} \quad \forall j = 1, 2, \dots, k.$$


donde:

- SCT_j es la suma de cuadrados totales de x_j .
- R_j^2 es el R^2 resultante de la regresión de x_j (como variable dependiente) sobre todas las demás variables independientes. En otras palabras, el R_j^2 indica cuánto de la variable x_j es explicado por los otros regresores.

Varianza del estimador de MCO

- $V(\hat{\beta}_j | \mathbf{X})$ es creciente en σ^2 :
 - ▣ Mientras más ruido haya, más difícil será estimar el efecto parcial de x_j sobre y .
- $V(\hat{\beta}_j | \mathbf{X})$ es decreciente en SCT_j :
 - ▣ Es decir, se prefiere una mayor variación muestral en x_j . Por ejemplo, aumentando el tamaño de la muestra.
- $V(\hat{\beta}_j | \mathbf{X})$ es creciente en R_j^2 :
 - ▣ El supuesto RLM.3 asegura que el $R_j^2 < 1$ pero nótese que cuando $R_j^2 \rightarrow 1$, entonces $V(\hat{\beta}_j | \mathbf{X}) \rightarrow \infty$. Esto se conoce como multicolinealidad.

Gráficamente



Multicolinealidad

- Se define como una correlación elevada pero no perfecta entre 2 o más variables explicativas.
- En muchos casos, la correlación elevada entre algunas variables resulta irrelevante. Por ejemplo, cuando x_2 y x_3 están muy correlacionadas entre sí pero éstas no se correlacionan con la variable de interés, x_1 .
- Un intento por reducir la varianza del estimador podría ser eliminar algún regresor y con ello disminuir el R_j^2 . Sin embargo, como se verá más adelante, la omisión de variables relevantes produce estimadores sesgados.
- En definitiva, no implica violación alguna de los supuestos anteriores y, por lo tanto, MCO sigue siendo MELI.

Supuestos

- Normalidad – $u \sim N(0, \sigma^2)$ (RLM.6):
 - ▣ El error poblacional es independiente de las variables explicativas y está distribuido normalmente, con media cero y varianza σ^2 .

- ▣ Esto implica que:

$$y|X \sim N(X\beta, \sigma^2)$$

- ▣ Este supuesto es clave para hacer inferencia acerca de los valores de parámetros.

Distribución del estimador de MCO

- La normalidad de los errores se traduce en distribuciones muestrales normales de los estimadores de MCO:

$$\hat{\beta}_j | \mathbf{X} \sim N(\beta_j, V(\hat{\beta}_j | \mathbf{X}))$$

- Esto implica que, condicional en los regresores:

$$\frac{\hat{\beta}_j - \beta_j}{\sqrt{V(\hat{\beta}_j | \mathbf{X})}} \sim N(0, 1)$$

- Sin embargo, $V(\hat{\beta}_j | \mathbf{X})$ depende de σ^2 que en la práctica es desconocido. Por lo tanto, debemos estimarlo. ¿Cómo?

Estimador MCO de σ^2

- Dado que los errores son inobservables, se utilizan los residuos de MCO:

$$\hat{\sigma}^2 = \left(\frac{1}{n - k - 1} \right) \times \sum_{i=1}^n \hat{u}_i^2$$

- Bajo los supuestos RLM.1 a RLM.5, $E(\hat{\sigma}^2 | \mathbf{X}) = \sigma^2$.
- Por lo tanto, bajo los supuestos RLM.1 a RLM.6, se cumple que, condicional en los regresores:

$$\frac{\hat{\beta}_j - \beta_j}{s.e.(\hat{\beta}_j)} \sim t_{n-k-1}$$

donde: $s.e.(\hat{\beta}_j) = \sqrt{\hat{V}(\hat{\beta}_j | \mathbf{X})}$.

```
. reg testscr str el_pct expn_stu
```

Source	SS	df	MS	Number of obs	=	420
Model	66409.8837	3	22136.6279	F(3, 416)	=	107.45
Residual	85699.7099	416	206.008918	Prob > F	=	0.0000
				R-squared	=	0.4366
				Adj R-squared	=	0.4325
Total	152109.594	419	363.030056	Root MSE	=	14.353

testscr	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
str	-.2863992	.4805232	-0.60	0.551	-1.230955	.658157
el_pct	-.6560227	.0391059	-16.78	0.000	-.7328924	-.5791529
expn_stu	.0038679	.0014121	2.74	0.006	.0010921	.0066437
_cons	649.5779	15.20572	42.72	0.000	619.6883	679.4676

Errores estándar

```
. estat vce
```

Covariance matrix of coefficients of **regress** model

e(V)	str	el_pct	expn_stu	_cons
str	.23090254			
el_pct	-.00344264	.00152927		
expn_stu	.00042012	-3.220e-06	1.994e-06	
_cons	-6.7125805	.06060743	-.01879395	231.21388

Test sobre un parámetro individual

- Suponga que desea evaluar si el coeficiente que acompaña a X_j es estadísticamente distinto de a_j . Es decir:

$$H_0: \beta_j = a_j$$

$$H_1: \beta_j \neq a_j$$

- En el caso particular en que $a_j = 0$, se busca determinar si X_j es una variable “significativa o relevante”. Si se rechaza H_0 , decimos entonces que X_j es significativa.
- Para esto usamos el estadístico t construido bajo H_0 :


$$t_{\hat{\beta}_j} = \frac{\hat{\beta}_j - a_j}{s.e.(\hat{\beta}_j)} \sim t_{n-k-1}$$

Test sobre un parámetro individual

- $t_{\widehat{\beta}_j}$ mide en cuántas desviaciones estándar estimadas de $\widehat{\beta}_j$ se aleja $\widehat{\beta}_j$ de a_j .
- Valores de $t_{\widehat{\beta}_j}$ alejados de 0 son evidencia contraria a H_0 .
- Suponga que se fija en α la probabilidad de cometer error del tipo I.
- Sea $t_{\alpha/2}$ el percentil $(1 - \alpha/2)$ de la distribución t -Student con $n - k - 1$ grados libertad.
- Entonces, se rechaza H_0 cuando:

$$\left| \frac{\widehat{\beta}_j - a_j}{s.e.(\widehat{\beta}_j)} \right| \geq t_{\alpha/2}$$

Gráficamente



Intervalo de confianza

- Además, sabemos que:

$$\left| \frac{\hat{\beta}_j - \beta_j}{s.e.(\hat{\beta}_j)} \right| \geq t_{\alpha/2}$$

es equivalente a decir que:

$$Pr \left(-t_{\alpha/2} \leq \frac{\hat{\beta}_j - \beta_j}{s.e.(\hat{\beta}_j)} \leq t_{\alpha/2} \right) = (1 - \alpha)$$

- Esto implica que el intervalo de confianza para β_j es:

$$\hat{\beta}_j - t_{\alpha/2} \times s.e.(\hat{\beta}_j) \leq \beta_j \leq \hat{\beta}_j + t_{\alpha/2} \times s.e.(\hat{\beta}_j)$$

- Si β_j no está en el intervalo, entonces se rechaza H_0 .

Valor-p

- Se define al valor-p de una prueba como:

$$Pr \left(|T| > \left| t_{\widehat{\beta}_j} \right| \right)$$

donde T es una variable t -Student con $n - k - 1$ grados libertad y $t_{\widehat{\beta}_j}$ es el valor del estadístico de contraste obtenido.

- En otras palabras, el valor-p es el mínimo nivel de significancia a partir del cual se rechaza H_0 .
- Por ejemplo, si se evalúa $H_0: \beta_j = 0$ y se obtiene un valor-p igual a 6.4%, se concluye que β_j es significativo a un nivel de significancia del 10% pero no al 5%.
- Entonces, valores-p pequeños son evidencia contraria a H_0 .

Test sobre un parámetro individual

- Considere ahora una hipótesis alternativa del tipo:

$$H_1: \beta_j > a_j \quad o \quad H_1: \beta_j < a_j$$

- Sin pérdida de generalidad, suponga un test cuya hipótesis alternativa es:

$$H_1: \beta_j < a_j$$

- Esto significa que valores positivos del estadístico $t_{\widehat{\beta}_j}$ no representan evidencia contraria a H_0 .
- Entonces, se rechaza H_0 en favor de H_1 cuando $t_{\widehat{\beta}_j} < -t_\alpha$.
- En estos test de 1 cola, el valor-p correspondiente es la mitad del valor-p del test de 2 colas.

Combinación lineal de parámetros

- Suponga ahora que queremos evaluar si $\beta_1 = \beta_2$. Esto se puede reescribir como:

$$H_0: \beta_1 - \beta_2 = 0$$

- Dado los estimadores de MCO siguen una distribución normal, su diferencia sigue también una distribución normal.
- Entonces, podemos utilizar el siguiente estadístico t :

$$\frac{\widehat{\beta}_1 - \widehat{\beta}_2}{s.e.(\widehat{\beta}_1 - \widehat{\beta}_2)} = \frac{\widehat{\beta}_1 - \widehat{\beta}_2}{\sqrt{\widehat{V}(\widehat{\beta}_1) + \widehat{V}(\widehat{\beta}_2) - 2 \times \widehat{C}(\widehat{\beta}_1, \widehat{\beta}_2)}} \sim t_{n-k-1}$$

- En definitiva, podemos aplicar este mismo enfoque para evaluar cualquier combinación lineal de parámetros.

Pruebas de exclusión

- Considere ahora el siguiente MRL múltiple:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + u$$

- Suponga que se desea probar que cuando controlamos por X_1 , las variables X_2 y X_3 no tienen efecto parcial sobre Y .
- Es decir:

$$H_0: \beta_2 = 0, \beta_3 = 0$$

- Hablamos entonces de 2 restricciones de exclusión bajo H_0 .
- Si rechazamos H_0 , decimos que X_2 y X_3 son conjuntamente significativas. El test no indica qué variable tiene un efecto significativo; puede ser una variable, la otra o ambas.

Pruebas de exclusión

- Este test puede pensarse como una comparación entre un modelo libre y un modelo sobre el cual se imponen las restricciones.
- En particular, se puede demostrar que:


$$F = \frac{(SCR_r - SCR_{sr})}{SCR_{sr}} \times \frac{(n - k - 1)}{q} \sim F(q, n - k - 1)$$

donde SCR_r es la suma de cuadrados residuales del modelo restringido, SCR_{sr} la del modelo libre o no restringido, $(n - k - 1)$ son los grados de libertad del modelo libre, y q es el número de restricciones bajo H_0 .

- ¿Intuición? Evaluar si aumento en la SCR al pasar del modelo libre al modelo restringido es lo suficientemente grande.

Gráficamente

- Valores de \hat{F} alejados de 0 son evidencia contraria a H_0 .
- Suponga que se fija en α la probabilidad de cometer error del tipo I.
- Entonces, se rechaza H_0 cuando $\hat{F} > F_\alpha(q, n - k - 1)$.



```
. reg testscr str
```

Source	SS	df	MS	Number of obs =	420
Model	7794.11004	1	7794.11004	F(1, 418) =	22.58
Residual	144315.484	418	345.252353	Prob > F =	0.0000
				R-squared =	0.0512
				Adj R-squared =	0.0490
Total	152109.594	419	363.030056	Root MSE =	18.581

testscr	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
str	-2.279808	.4798256	-4.75	0.000	-3.22298	-1.336637
_cons	698.933	9.467491	73.82	0.000	680.3231	717.5428

```
. reg testscr str el_pct expn_stu
```

Source	SS	df	MS	Number of obs =	420
Model	66409.8837	3	22136.6279	F(3, 416) =	107.45
Residual	85699.7099	416	206.008918	Prob > F =	0.0000
				R-squared =	0.4366
				Adj R-squared =	0.4325
Total	152109.594	419	363.030056	Root MSE =	14.353

testscr	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
str	-.2863992	.4805232	-0.60	0.551	-1.230955	.658157
el_pct	-.6560227	.0391059	-16.78	0.000	-.7328924	-.5791529
expn_stu	.0038679	.0014121	2.74	0.006	.0010921	.0066437
_cons	649.5779	15.20572	42.72	0.000	619.6883	679.4676

```
. reg testscr str el_pct expn_stu
```

Source	SS	df	MS	Number of obs = 420		
Model	66409.8837	3	22136.6279	F(3, 416) = 107.45		
Residual	85699.7099	416	206.008918	Prob > F = 0.0000		
Total	152109.594	419	363.030056	R-squared = 0.4366		
				Adj R-squared = 0.4325		
				Root MSE = 14.353		

testscr	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
str	-.2863992	.4805232	-0.60	0.551	-1.230955	.658157
el_pct	-.6560227	.0391059	-16.78	0.000	-.7328924	-.5791529
expn_stu	.0038679	.0014121	2.74	0.006	.0010921	.0066437
_cons	649.5779	15.20572	42.72	0.000	619.6883	679.4676

```
. test el_pct expn_stu
```

- (1) el_pct = 0
- (2) expn_stu = 0

```
F( 2, 416) = 142.27
Prob > F = 0.0000
```

$$\rightarrow F = \frac{(144315.48 - 85699.71)}{85699.71} \times \frac{(420 - 3 - 1)}{2} = 142.27$$

Contraste de regresión

- También conocido como test de significancia general o global.
- La hipótesis nula establece que ninguna variable explicativa tiene efecto sobre Y . Es decir:

$$H_0: \beta_1 = \beta_2 = \dots = \beta_k = 0$$

- Entonces, el modelo restringido es:

$$Y = \beta_0 + u,$$

cuyo R^2 es igual a 0.

- Por lo tanto, el estadístico F se puede escribir a partir del R^2 del modelo no restringido:

$$F = \frac{R^2}{(1 - R^2)} \times \frac{(n - k - 1)}{k}$$

```
. reg testscr str el_pct expn_stu
```

Source	SS	df	MS
Model	66409.8837	3	22136.6279
Residual	85699.7099	416	206.008918
Total	152109.594	419	363.030056

Number of obs = 420

F(3, 416) = 107.45

Prob > F = 0.0000

R-squared = 0.4366

Adj R-squared = 0.4325

Root MSE = 14.353

testscr	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
str	-.2863992	.4805232	-0.60	0.551	-1.230955	.658157
el_pct	-.6560227	.0391059	-16.78	0.000	-.7328924	-.5791529
expn_stu	.0038679	.0014121	2.74	0.006	.0010921	.0066437
_cons	649.5779	15.20572	42.72	0.000	619.6883	679.4676

```
. test str el_pct expn_stu
```

```
( 1) str = 0
```

```
( 2) el_pct = 0
```

```
( 3) expn_stu = 0
```

F(3, 416) = 107.45

Prob > F = 0.0000

$$\rightarrow F = \frac{0.4366}{(1 - 0.4366)} \times \frac{(420 - 3 - 1)}{3} = 107.45$$