

# Econometría

Diplomado Banco Central de Honduras

Instituto de Economía

Pontificia Universidad Católica de Chile

Juan Ignacio Urquiza – Junio 2022

# Modelo de Regresión Lineal Clásico

## □ Supuestos:

- Linealidad en parámetros (RLM.1).
- Muestreo aleatorio (RLM.2).
- Colinealidad imperfecta (RLM.3).
- Media condicional cero (RLM.4).
- Homocedasticidad (RLM.5).

## □ En la clase 2 demostramos que:

- Bajo los supuestos RLM.1 a RLM.4, los estimadores de MCO son insesgados.
- Bajo los supuestos RLM.1 a RLM.5, los estimadores de MCO son MELI – Teorema de Gauss-Markov.

# Heterocedasticidad

- Los errores son heterocedásticos si su varianza condicional en los regresores no es constante.
- ¿Cuáles son las consecuencias?
  - ▣ Los estimadores de MCO siguen siendo insesgados pero dejan de ser MELI.
  - ▣ Los estimadores de las varianzas  $V(\hat{\beta}_j | \mathbf{X})$  son sesgados y por ende dejan de ser válidos para hacer inferencia.
  - ▣ Los estadísticos  $t$  de MCO no tienen distribuciones  $t$ , ni los estadísticos  $F$  siguen distribuciones  $F$ .
  - ▣ Estos problemas no se resuelven con tamaños de muestra grandes.

# Heterocedasticidad

- Los errores son heterocedásticos si su varianza condicional en los regresores no es constante.
- ¿Cuáles son las consecuencias?
  - ▣ Los estimadores de MCO siguen siendo insesgados pero dejan de ser MELI.
- Antes de abandonar MCO, podemos implementar una prueba formal que detecte la presencia de heterocedasticidad.
- Si se detecta heterocedasticidad, hacemos inferencia robusta:
  - ▣ Consiste en mantener MCO pero ajustando los errores estándar para que sean válidos en presencia de heterocedasticidad de forma desconocida.

# Prueba de Breusch-Pagan

- Considere el MRL múltiple:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k + u$$

- La hipótesis nula de homocedasticidad implica que:

$$H_0: V(u|x_1, x_2, \dots, x_k) = \sigma^2$$

- Dado el supuesto de media condicional nula, es equivalente a:

$$H_0: E(u^2|x_1, x_2, \dots, x_k) = \sigma^2$$

- Entonces, la prueba consiste en evaluar si  $u^2$  está relacionado (en valor esperado) con una o más variables explicativas.

- Una forma de hacerlo es suponiendo un modelo sencillo:

$$u^2 = \delta_0 + \delta_1 x_1 + \delta_2 x_2 + \cdots + \delta_k x_k + v$$

$$\rightarrow H_0: \delta_1 = \delta_2 = \cdots = \delta_k = 0$$

# Prueba de Breusch-Pagan

- Como los errores son inobservables, se utilizan los residuos:

$$\hat{u}^2 = \delta_0 + \delta_1 x_1 + \delta_2 x_2 + \cdots + \delta_k x_k + error$$

- Luego se calcula el estadístico  $F$  para la significancia conjunta de las variables explicativas:

$$F = \frac{R_{\hat{u}^2}^2}{(1 - R_{\hat{u}^2}^2)} \times \frac{(n - k - 1)}{k} \xrightarrow{a} F(k, n - k - 1)$$

donde  $R_{\hat{u}^2}^2$  es el  $R^2$  de la regresión auxiliar anterior.

- Si se rechaza  $H_0$ , entonces los errores son heterocedásticos.

```
. reg testscr str el_pct expn_stu
```

Source	SS	df	MS	Number of obs = 420		
Model	66409.8837	3	22136.6279	F( 3, 416) = 107.45		
Residual	85699.7099	416	206.008918	Prob > F = 0.0000		
Total	152109.594	419	363.030056	R-squared = 0.4366		
				Adj R-squared = 0.4325		
				Root MSE = 14.353		

  

testscr	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
str	-.2863992	.4805232	-0.60	0.551	-1.230955	.658157
el_pct	-.6560227	.0391059	-16.78	0.000	-.7328924	-.5791529
expn_stu	.0038679	.0014121	2.74	0.006	.0010921	.0066437
_cons	649.5779	15.20572	42.72	0.000	619.6883	679.4676

```
. estat hett, rhs fstat
```

Breusch-Pagan / Cook-Weisberg test for heteroskedasticity

Ho: Constant variance

Variables: str el\_pct expn\_stu

F(3 , 416) = 14.84

Prob > F = 0.0000

# Inferencia robusta

- Recuerde que en el MRL simple:

$$\widehat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \beta_1 + \frac{\sum_{i=1}^n (x_i - \bar{x})u_i}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

- Bajo el supuesto de homocedasticidad, sabemos que:

$$V(\widehat{\beta}_1|X) = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sigma^2}{SCT_x}$$

- Bajo heterocedasticidad,  $V(u_i|x_i) = \sigma_i^2$ , lo que implica que:

$$V(\widehat{\beta}_1|X) = \frac{\sum_{i=1}^n (x_i - \bar{x})^2 \sigma_i^2}{SCT_x^2}$$

- Cuando  $\sigma_i^2 = \sigma^2 \forall i$  estas fórmulas coinciden, pero si  $\sigma_i^2 \neq \sigma^2$  vemos que la fórmula usual ya no es válida.



# Inferencia robusta

- Se puede demostrar que un estimador válido de esta varianza se obtiene al reemplazar  $\sigma_i^2$  (desconocido) por  $\hat{u}_i^2$  tal que:

$$\hat{V}(\hat{\beta}_1|X) = \frac{\sum_{i=1}^n (x_i - \bar{x})^2 \hat{u}_i^2}{SCT_x^2}$$

- Naturalmente, este análisis se extiende al MRL múltiple.
- La raíz cuadrada de  $\hat{V}(\hat{\beta}_j|X)$  constituye el estándar robusto.
- Una vez obtenidos los errores estándar robustos, es fácil construir un estadístico  $t$  robusto:

$$t = \frac{\text{estimación} - \text{valor hipotético}}{\text{error estándar robusto}}$$

```
. reg testscr str el_pct expn_stu
```

Source	SS	df	MS	Number of obs	=	420
Model	66409.8837	3	22136.6279	F(3, 416)	=	107.45
Residual	85699.7099	416	206.008918	Prob > F	=	0.0000
				R-squared	=	0.4366
				Adj R-squared	=	0.4325
Total	152109.594	419	363.030056	Root MSE	=	14.353

testscr	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
str	-.2863992	.4805232	-0.60	0.551	-1.230955	.658157
el_pct	-.6560227	.0391059	-16.78	0.000	-.7328924	-.5791529
expn_stu	.0038679	.0014121	2.74	0.006	.0010921	.0066437
_cons	649.5779	15.20572	42.72	0.000	619.6883	679.4676

```
. reg testscr str el_pct expn_stu, robust
```

Linear regression

Number of obs = 420  
 F(3, 416) = 147.20  
 Prob > F = 0.0000  
 R-squared = 0.4366  
 Root MSE = 14.353

testscr	Coef.	Robust Std. Err.	t	P> t	[95% Conf. Interval]	
str	-.2863992	.4820728	-0.59	0.553	-1.234002	.661203
el_pct	-.6560227	.0317844	-20.64	0.000	-.7185008	-.5935446
expn_stu	.0038679	.0015807	2.45	0.015	.0007607	.0069751
_cons	649.5779	15.45834	42.02	0.000	619.1917	679.9641

# Inferencia robusta

- En este ejemplo se pueden observar varias cosas:
  - ▣ Los errores estándar no son muy diferentes. Esto ocurre a menudo, pero no tiene por qué ser así.
  - ▣ En este caso particular, las variables que son significativas empleando el estadístico  $t$  usual lo siguen siendo cuando se emplea el estadístico  $t$  robusto.
  - ▣ Los errores estándar robustos pueden ser mayores o menores que los errores estándar usuales. Sin embargo, por lo general son mayores.

# Observaciones no independientes

- Recién vimos qué pasaba cuando se levantaba el supuesto de homocedasticidad (RLM.5).
- Ahora veremos qué ocurre cuando las observaciones no son independientes. Es decir, cuando se viola el supuesto (RLM.2).

- ▣ En general, hablaremos de dependencia de los errores.

- Formalmente, existe dependencia de los errores cuando:

$$E(u_i u_j) = Cov(u_i, u_j) \neq 0 \text{ para } i \neq j.$$

- Es decir, cuando el término de error de una observación está correlacionado con el término de error de otra.

# Dependencia de los errores

- ¿Cuáles son las consecuencias?
  - ▣ Los estimadores de MCO siguen siendo insesgados; sin embargo, la dependencia de los errores causa problemas a la hora de estimar la varianza de los estimadores.
  - ▣ Por lo tanto, los errores estándar de MCO y los estadísticos de contraste usuales dejan de ser válidos.
- Antes de abandonar MCO, podemos implementar una prueba que detecte la presencia de correlación de los errores.
- Si detectamos correlación, hacemos inferencia robusta:
  - ▣ Consiste en mantener MCO pero ajustando los errores estándar para que sean válidos en presencia de correlación serial.

# MCO con errores correlacionados

- Considere el MRL simple:  $y_t = \beta_0 + \beta_1 x_t + u_t$ .
- Por simplicidad, suponga que  $\bar{x} = 0$  tal que el estimador de  $\beta_1$  de MCO puede escribirse como:

$$\widehat{\beta}_1 = \beta_1 + SCT_x^{-1} \sum_{t=1}^T x_t u_t$$

- Se puede demostrar que la varianza condicional es igual a:

$$\begin{aligned} V(\widehat{\beta}_1 | x_t) &= SCT_x^{-2} \times Var \left( \sum_{t=1}^T x_t u_t \right) \\ &= SCT_x^{-2} \left[ \sum_{t=1}^T x_t^2 V(u_t) + 2 \sum_{t=1}^{T-1} \sum_{j=1}^{T-t} x_t x_{t+j} E(u_t u_{t+j}) \right] \end{aligned}$$

# MCO con errores correlacionados

- El primer término corresponde a la varianza del estimador de MCO cuando no hay correlación de los errores.
- Por lo tanto, si los errores están correlacionados, el estimador usual de la varianza es sesgado.
- En la mayoría de las aplicaciones económicas, tanto las v. explicativas y como los errores suelen presentar correlación serial positiva.
- Entonces, la fórmula usual de la varianza de MCO suele subestimar la verdadera varianza.
- En cualquier caso, esto implica que en presencia de errores correlacionados, los estadísticos de contraste usuales ya no pueden ser utilizados para probar hipótesis.

# Prueba de Breusch-Godfrey

- Considere el MRL múltiple con correlación serial de orden 1:

$$y_t = \beta_0 + \beta_1 x_{t,1} + \cdots + \beta_k x_{t,k} + u_t,$$

$$\rightarrow u_t = \rho u_{t-1} + \varepsilon_t$$

- La hipótesis nula de no correlación serial implica que:

$$H_0: \rho = 0$$

- Si pudiéramos observar  $u_t$ , entonces podríamos estimar  $\rho$  a partir de la regresión de  $u_t$  sobre  $u_{t-1}$ .
- Sin embargo, como los errores son inobservables, usamos los residuos de MCO.
- Entonces, primero se estima la regresión original por MCO y se obtienen los residuos ( $\hat{u}_t$ ) para  $t = 1, 2, \dots, T$ .



# Prueba de Breusch-Godfrey

- Luego se estima por MCO la regresión auxiliar de los residuos sobre su primer rezago para probar  $H_0$ .
- Alternativamente, se estima la regresión auxiliar controlando por todas las v. explicativas, y se utiliza el estadístico  $ML$ :

$$\hat{u}_t = \rho \hat{u}_{t-1} + \delta_1 x_{t1} + \cdots + \delta_k x_{tk} + e_t$$

$$ML = (T - 1) \times R_{\hat{u}}^2 \xrightarrow{a} \chi_q^2$$

donde  $(T - 1)$  es el tamaño efectivo de la muestra y  $R_{\hat{u}}^2$  es el  $R^2$  de la regresión auxiliar.

- Si  $ML > \chi_q^2$ , se rechaza  $H_0$  y decimos que hay evidencia en favor de la presencia de correlación serial (o autocorrelación).

**. reg i3 inf def**

Source	SS	df	MS	Number of obs	=	56
				F(2, 53)	=	<b>40.09</b>
Model	<b>272.420338</b>	<b>2</b>	<b>136.210169</b>	Prob > F	=	<b>0.0000</b>
Residual	<b>180.054275</b>	<b>53</b>	<b>3.39725047</b>	R-squared	=	<b>0.6021</b>
				Adj R-squared	=	<b>0.5871</b>
Total	<b>452.474612</b>	<b>55</b>	<b>8.22681113</b>	Root MSE	=	<b>1.8432</b>

i3	Coefficient	Std. err.	t	P> t	[95% conf. interval]	
inf	<b>.6058659</b>	<b>.0821348</b>	<b>7.38</b>	<b>0.000</b>	<b>.4411243</b>	<b>.7706074</b>
def	<b>.5130579</b>	<b>.1183841</b>	<b>4.33</b>	<b>0.000</b>	<b>.2756095</b>	<b>.7505062</b>
_cons	<b>1.733266</b>	<b>.431967</b>	<b>4.01</b>	<b>0.000</b>	<b>.8668497</b>	<b>2.599682</b>

**. estat bgodfrey, lag(1) nomiss0**

Breusch–Godfrey LM test for autocorrelation

lags(p)	chi2	df	Prob > chi2
1	<b>21.553</b>	<b>1</b>	<b>0.0000</b>

H0: no serial correlation

```
. predict u, r
```

```
. reg u L.u inf def
```

Source	SS	df	MS	Number of obs	=	55
Model	66.3679315	3	22.1226438	F(3, 51)	=	10.95
Residual	102.993175	51	2.01947402	Prob > F	=	0.0000
				R-squared	=	0.3919
				Adj R-squared	=	0.3561
Total	169.361106	54	3.13631678	Root MSE	=	1.4211

  

u	Coefficient	Std. err.	t	P> t	[95% conf. interval]	
u L1.	.62339	.1111842	5.61	0.000	.4001784	.8466015
inf	.0066283	.0657049	0.10	0.920	-.1252798	.1385364
def	-.1105103	.1009978	-1.09	0.279	-.3132719	.0922513
_cons	.1795108	.3352319	0.54	0.595	-.4934953	.8525169

$$\rightarrow LM = (T - 1) \times R_{\hat{u}}^2 = (56 - 1) \times 0.3919 \cong 21.55$$

**TABLE C: Chi-Square distributions**

cum probability	0.025	0.80	0.90	0.95	0.975	0.99	0.995	0.999	0.9995
right tail	0.975	0.2	0.1	0.05	0.025	0.01	0.005	0.001	0.0005
df									
1	0.00098	1.64	2.71	3.84	5.02	6.63	7.88	10.83	12.12
2	0.051	3.22	4.61	5.99	7.38	9.21	10.60	13.82	15.20
3	0.216	4.64	6.25	7.81	9.35	11.34	12.84	16.27	17.73
4	0.48	5.99	7.78	9.49	11.14	13.28	14.86	18.47	20.00
5	0.83	7.29	9.24	11.07	12.83	15.09	16.75	20.51	22.11
6	1.24	8.56	10.64	12.59	14.45	16.81	18.55	22.46	24.10
7	1.69	9.80	12.02	14.07	16.01	18.48	20.28	24.32	26.02
8	2.18	11.03	13.36	15.51	17.53	20.09	21.95	26.12	27.87
9	2.70	12.24	14.68	16.92	19.02	21.67	23.59	27.88	29.67
10	3.25	13.44	15.99	18.31	20.48	23.21	25.19	29.59	31.42
11	3.82	14.63	17.28	19.68	21.92	24.73	26.76	31.26	33.14
12	4.40	15.81	18.55	21.03	23.34	26.22	28.30	32.91	34.82
13	5.01	16.98	19.81	22.36	24.74	27.69	29.82	34.53	36.48
14	5.63	18.15	21.06	23.68	26.12	29.14	31.32	36.12	38.11
15	6.26	19.31	22.31	25.00	27.49	30.58	32.80	37.70	39.72
16	6.91	20.47	23.54	26.30	28.85	32.00	34.27	39.25	41.31
17	7.56	21.61	24.77	27.59	30.19	33.41	35.72	40.79	42.88
18	8.23	22.76	25.99	28.87	31.53	34.81	37.16	42.31	44.43
19	8.91	23.90	27.20	30.14	32.85	36.19	38.58	43.82	45.97
20	9.59	25.04	28.41	31.41	34.17	37.57	40.00	45.31	47.50
21	10.28	26.17	29.62	32.67	35.48	38.93	41.40	46.80	49.01
22	10.98	27.30	30.81	33.92	36.78	40.29	42.80	48.27	50.51
23	11.69	28.43	32.01	35.17	38.08	41.64	44.18	49.73	52.00
24	12.40	29.55	33.20	36.42	39.36	42.98	45.56	51.18	53.48
25	13.12	30.68	34.38	37.65	40.65	44.31	46.93	52.62	54.95
30	16.79	36.25	40.26	43.77	46.98	50.89	53.67	59.70	62.16
40	24.43	47.27	51.81	55.76	59.34	63.69	66.77	73.40	76.10
50	32.36	58.16	63.17	67.50	71.42	76.15	79.49	86.66	89.56
60	40.48	68.97	74.40	79.08	83.30	88.38	91.95	99.61	102.7
80	57.15	90.41	96.58	101.9	106.6	112.3	116.3	124.8	128.3
100	74.22	111.7	118.5	124.3	129.6	135.8	140.2	149.4	153.2

# Inferencia robusta

- Recuerde que en el MRL simple, la varianza condicional de  $\widehat{\beta}_1$  viene dada por:

$$V(\widehat{\beta}_1|x_t) = SCT_x^{-2} \left[ \sum_{t=1}^T x_t^2 V(u_t) + 2 \sum_{t=1}^{T-1} \sum_{j=1}^{T-t} x_t x_{t+j} E(u_t u_{t+j}) \right]$$

- Por lo tanto, si los errores están serialmente correlacionados, es necesario tomar en cuenta la correlación entre  $u_t$  y  $u_{t+j}$ .
- En la práctica, es común suponer que una vez que los términos de error están alejados por más de unos cuantos períodos, dicha correlación es fundamentalmente 0.
- Para ello, se debe elegir un número entero  $J > 0$  que controle cuánta correlación serial se estará permitiendo en el cálculo.

# Inferencia robusta

- Entonces, el error estándar robusto viene dado por la raíz de:

$$\hat{V}(\hat{\beta}_1|x_t) = SCT_x^{-2} \left[ \sum_{t=1}^T x_t^2 \hat{u}_t^2 + 2 \sum_{j=1}^J \sum_{t=j+1}^T w_j x_t x_{t-j} \hat{u}_t \hat{u}_{t-j} \right]$$

donde  $w_j = \left(1 - \frac{j}{J+1}\right)$ .

- Estos errores estándar de Newey-West son robustos tanto a la heterocedasticidad como a la correlación serial (HAC).
- El número de rezagos se elige según la frecuencia de los datos: anual (1 a 3), trimestral (4 a 12), mensual (12 a 36).
- En Stata, simplemente utilizamos el comando “newey” (después de “tsset”), especificando el número de rezagos.

**. reg i3 inf def**

Source	SS	df	MS	Number of obs	=	56
				F(2, 53)	=	40.09
Model	272.420338	2	136.210169	Prob > F	=	0.0000
Residual	180.054275	53	3.39725047	R-squared	=	0.6021
				Adj R-squared	=	0.5871
Total	452.474612	55	8.22681113	Root MSE	=	1.8432

i3	Coefficient	Std. err.	t	P> t	[95% conf. interval]	
inf	.6058659	.0821348	7.38	0.000	.4411243	.7706074
def	.5130579	.1183841	4.33	0.000	.2756095	.7505062
_cons	1.733266	.431967	4.01	0.000	.8668497	2.599682

**. newey i3 inf def, lag(3)**

Regression with Newey–West standard errors      Number of obs      =      56  
Maximum lag = 3      F( 2, 53) =      18.32  
Prob > F      =      0.0000

i3	Coefficient	Newey–West std. err.	t	P> t	[95% conf. interval]	
inf	.6058659	.1075138	5.64	0.000	.3902205	.8215112
def	.5130579	.2196756	2.34	0.023	.0724444	.9536713
_cons	1.733266	.5438208	3.19	0.002	.6424995	2.824032