


Inferencia

1. Distribuciones muestrales de estimadores



▶ Nos hablan de momentos de la distribución muestral de los estimadores → Pero la distribución depende del término de error u

▶ NORMALIDAD MLR6 de los errores

El error poblacional u es **independiente** de los regresores x_1, \dots, x_K y se distribuye en forma normal con **media cero** y **varianza σ^2**

$$u \sim N(0, \sigma^2)$$

- $E(u|x_1, \dots, x_K) = E(u) = 0$ RLM4
- $\text{Var}(u|x_1, \dots, x_K) = \text{Var}(u) = \sigma^2$ RLM5

→ Modelo lineal Clásico (CLM)

- MLR1 + MLR5 + MLR6
- Gauss Markow + Normalidad
- f.d.p.

⇒ MLE son estimadores **insegamados de mínima varianza** (no es necesario que sean lineales en y_j)

$$y|x_1, \dots, x_K = y|x \sim N(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_K x_K, \sigma^2)$$

Problemas

- Variables que **no** distribuyen normal
 - Ingresos
 - N° libros
 - N° educacional

Pero en análisis asíntotico se soluciona
(Muestras grandes)

$$\hat{\beta}_j|x \sim \text{Normal}(\beta_j, \text{Var}(\hat{\beta}_j|x))$$

$$\frac{\hat{\beta}_j - \beta_j}{\text{sd}(\hat{\beta}_j)}|x \sim N(0, 1)$$

Demostración

$$\hat{\beta}_j = \beta_j + \frac{\sum u_i}{\sum x_{ij}} \text{ independiente de } x_i$$

$$\hat{\beta}_j = \beta_j + c \cdot u_i \Rightarrow \hat{\beta}_j \text{ es combinación lineal de errores } u_i$$

→ MLR6 + (y MLR2), los errores son v.a iid Normal $(0, \sigma^2)$

→ La suma de u_i iid \sim Normal, también se distribuye normal

→ $\hat{\beta}_j|x$ también distribuye normal con media β_j y $\text{Var}(\hat{\beta}_j|x)$

2. Prueba de hipótesis

□ Nunca sabemos los valores exactos de β_j → PRUEBAS de HIPÓTESIS

T-student (único parámetro)

F (multiples parámetros)

T STUDENT - ÚNICO PARÁMETRO

$$\frac{\hat{\beta}_j - \beta_j}{\text{se}(\hat{\beta}_j)}|x \sim t_{n-K-1} = t_{\beta_j}$$

test dos colas con $H_0: \beta_j = 0$

$t_{\beta_j} = \frac{\hat{\beta}_j}{\text{se}(\hat{\beta}_j)}$

↓ desconocido, σ^2 muestral

$$\begin{cases} H_0: \beta_j = 0 \\ H_1: \beta_j \neq 0 \end{cases} \quad \left. \begin{array}{l} \text{El efecto parcial de } x_j \\ \text{sobre } y, \text{ después de} \\ \text{controlar por el resto de } x \end{array} \right.$$

→ Hipótesis es acerca de **parámetros poblacionales**

$|t_{\beta_j}|$ muy grande

LEFT TAILED (muy negativas)
RIGHT TAILED (muy positivas)

$$t_c = \text{en el percentil } 1 - \alpha \text{ en } \frac{n-K-1}{GL}$$

t_{β_j} compara t_c → zona de rechazo a un nivel de confianza

■ P-value

$$P(|T| > |t|)$$

- Fuerza o debilidad de evidencia empírica sobre H_0
- p-value se compara nivel de confianza (mínimo)
 - altamente significativa 0.01
 - significativa 0.05
 - marginalmente significativa 0.1

■ Intervalos de confianza

$$\hat{\beta}_j \pm t_c \cdot \text{se}(\hat{\beta}_j)$$

En sucesivas muestras aleatorias, computando $\hat{\beta}_j \pm \text{se}(\hat{\beta}_j)$, el valor poblacional β_j se encontraría en el intervalo $(\hat{\beta}_j - t_c \cdot \text{se}(\hat{\beta}_j), \hat{\beta}_j + t_c \cdot \text{se}(\hat{\beta}_j))$ en un 95% de muestras

- $t_c = \text{percentil } 97.5$ en distribución t_{n-K-1}

- Con un 95% de confianza sabemos si el estimador puntual está en el intervalo

STATA

- reg
- esttab reg
- esttab

STATA

$$\text{ECONÓMICAMENTE} \rightarrow \frac{\log y}{\log x} = \text{ELASTICIDADES} \rightarrow \log(\text{wage}) (\text{como \%})$$

PRUEBA F

- Prueba para un grupo de variables (q) que pertenecen a K

Modelo no restringido

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_K x_K + u$$

Modelo restringido

$$y = \beta_0 + \beta_1 x_1 + \dots + \beta_{K-q} x_{K-q} + u$$

HIPÓTESIS

- Probaremos que q de estas K variables no tienen un efecto parcial en y

$$H_0: \beta_{K-q+1} = \dots = \beta_K = 0$$

q restricciones de exclusión

H_1 : que H_0 no es verdadero

restricción es más mejor que 0.

- $SSR_{NR} \leq SSR_R$

En MCO, al agregar más variables $\uparrow R^2$ ($\downarrow SSR$)

¿Es estadísticamente significativa la diferencia?

STATA
test var1 var2 var3

$$F = \frac{SSR_R - SSR_{NR}}{SSR_{NR}/(n-K-1)}$$

- Rechazamos H_0

$$F_{obs} > F_{teórico}$$

Parámetros

q
 $n-K-1$
 IC

$\rightarrow q$ (en conjunto) son estadísticamente significativas sobre y

- Contextos de uso de F

Alta correlación de predictores
Si x_1, x_2 ↑ correlación, ↑ sd($\hat{\beta}_1$), ↓ t.
(Ej: x_1 educación padre, x_2 educación madre, y = rendimiento académico)

Variables que comparten covarianza conjunta para explicar y

Chequear corr entre variables

MULTICOLINELARIDAD ES MENOS RELEVANTE EN PRUEBAS CONJUNTAS (F)

F ÚTIL PARA PRUEBAS DE EXCLUSIÓN CONJUNTA

RELACIÓN ENTRE R Y F

$$SST = \sum_{i=1}^n (y_i - \bar{y})^2 \quad SSE = \sum_{i=1}^n (\hat{y}_i - y_i)^2 \quad SSR = \sum_{i=1}^n (\hat{y}_i - y_i)^2 = \sum_{i=1}^n \hat{u}_i^2 \quad R^2 = \frac{SSE}{SST} = 1 - \frac{SSR}{SST}$$

$$SSR_R = SST (1 - R^2_R) \quad SSR_{NR} = SST (1 - R^2_{NR})$$

$$F = \frac{(SSR_R - SSR_{NR}) / SST}{SSR_R / SST} \times \frac{(n - K - 1)}{q} \rightarrow \frac{(R^2_{NR} - R^2_R)}{(1 - R^2_R)} \times \frac{(n - K - 1)}{q}$$

Relación F con tudent

Para un solo parámetro

t^2_{n-K-1} tiene una distribución

$$F_{(1, n-K-1)}$$

OJO F no se utiliza siempre

■ t + flexible para pruebas de un parámetro
■ F (-) poder para determinar H_0 .

Rechazar H_0 cuando ... Poder = 1 - P(Erro tipo II | H_0)

error de rechazar H_0

↑ rechazo pequeño

* Lo contrario a nivel de significancia

■ F nos habla de conjuntos. Algunos parámetros pueden no ser sig. individualmente, pero sí en conjunto

F-ESTADÍSTICO GLOBAL

$$H_0: \beta_1 = \beta_2 = \dots = \beta_K = 0$$

- Modelos $y = \beta_0 + u$

■ $R^2 = 0 \rightarrow$ nada de la variación de y es explicada por los no predictores

$$F = \frac{R^2_{NR}}{(1 - R^2_{NR})} \times \frac{(n - K - 1)}{(K)} \rightarrow \text{Nótese que no es q.}$$

SIGNIFICANCIA CONJUNTA DE TODOS LOS REGRESORES

EN STATA

$$H_0: \beta_1 = 1, \beta_2 = 0, \beta_3 = 0$$

STATA
reg var1 var2 var3
test var2 var3 (los no significativos) } test (var1=1) (var2=0) (var3=0)
test var1=1 (H0) } si F pequeño, para no rechazar H_0

3. INFERENCIA EN TÉRMINOS MATEMÁTICOS

TESTAR MÚLTIPLES HIPÓTESIS ACERCA DE PARÁMETROS

$$1. \quad H_0: R\beta = r \quad vs \quad H_1: R\beta \neq r$$

R matriz $q \times (K+1)$

r vector $q \times 1$ con $q \leq K+1$ restricciones lineales

$$2. \quad \begin{bmatrix} r_{1,0} & \dots & r_{1,K} \\ \vdots & \ddots & \vdots \\ r_{q,0} & \dots & r_{q,K} \end{bmatrix} \begin{bmatrix} \beta_0 \\ \vdots \\ \beta_K \end{bmatrix} = \begin{bmatrix} r_1 \\ \vdots \\ r_q \end{bmatrix}$$

HIPÓTESIS SIMPLE $H_0: \beta_1 = 1$

$$R = [0 \ 1 \ 0 \ \dots \ 0], r = 1$$

HIPÓTESIS IGUALDAD $H_0: \beta_1 = \beta_2, \beta_1 - \beta_2 = 0$

$$R = [0 \ 1 \ -1 \ \dots \ 0], r = 0$$

HIPÓTESIS CONJUNTA $H_0: \beta_0 = 2, \beta_1 = 1 - \beta_2, \beta_1 + \beta_2 = 1$

$$R = [1 \ 0 \ 0 \ \dots \ 0] \quad r = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

3. TEST F

$$F = (R\hat{\beta} - r)' (\hat{\sigma}^2 R(X'X)^{-1} R')^{-1} (R\hat{\beta} - r) / q \sim F(q, n-K-1)$$


DEMOSTRACIÓN

• Por MLRG sabemos que la normalidad de errores, condicional en X, implica $\hat{\beta} \sim N(\beta, \sigma^2(X'X)^{-1})$

E2-E.4

3. IEDÍ

$$F = (\hat{R}\hat{\beta} - r)' (\hat{\sigma}^2 R(X'X)^{-1} R')^{-1} (\hat{R}\hat{\beta} - r) / q \sim F_{q, n-k-1}$$



DEMOSTRACIÓN

- Por MLRG sabemos que la normalidad de errores, condicional en X , implica $\hat{\beta} \sim N(\beta, \hat{\sigma}^2(X'X)^{-1})$

Entonces

$$\begin{aligned} R\hat{\beta} &\sim N(R\beta, \hat{\sigma}^2 R(X'X)^{-1} R') \\ (R\hat{\beta} - R\beta) &\sim N(0, \hat{\sigma}^2 R(X'X)^{-1} R) \end{aligned}$$

Bajo H_0 podemos demostrar que

$$(R\hat{\beta} - r)' [\hat{\sigma}^2 R(X'X)^{-1} R]^{-1} (R\hat{\beta} - r) \sim \chi^2(q)$$

Como $\hat{\sigma}^2$ es desconocido, usamos su estimador y se obtiene (1) con distribución F de Fisher.

E.2-E.4

B. T-STUDENT

Recordemos que $t_{n-k-1}^2 \sim F_{q, n-k-1}$ ^{parametro}

$$\frac{\hat{\beta}_1 - \hat{\beta}_2}{\text{se}(\hat{\beta}_1 - \hat{\beta}_2)} = \frac{\hat{\beta}_1 - \hat{\beta}_2}{\sqrt{V(\hat{\beta}_1) + V(\hat{\beta}_2) - 2C(\hat{\beta}_1, \hat{\beta}_2)}} \sim t_{n-k-1}$$

$$H_0: \hat{\beta}_1 = \hat{\beta}_2 \quad \boxed{\hat{\beta}_1 - \hat{\beta}_2 = 0}$$